

# الذكاء الاصطناعي في التعليم: نحو التعلم الشخصي

مصعب موسى

# المقدمة: التحدي في التخصيص التعليمي



## المشكلة

المشكلة تكمن في صعوبة تقديم تجربة تعلم شخصية لكل طالب على حدة في البيئات التعليمية التقليدية، مما يؤدي إلى تفاوت في النتائج وتزايد عبء العمل على المعلمين.

## لماذا هذا المشروع مهم؟

- **للطالب:** زراعة المشاركة والتحصيل الأكاديمي وتقليل التسرب\*\*
- **للمعلم:** توفير الوقت عبر أتمنة مهام التقييم الروتينية وتحديد الطلاب المعرضين للخطر\*\*
- **التأثير المتوقع:** تحويل التعليم إلى نظام أكثر كفاءة وموجه نحو احتياجات المتعلم\*\*

# أهداف المشروع

- و مقاييس الأداء لإنشاء مجموعة بيانات جاهزة للنموذج (LMS logs) **الهدف الأول (البيانات)**: جمع و تنظيف بيانات سلوك المتعلمين
- الهدف الثاني (التحليل)**: إجراء تحليل استكشافي لتحديد الأنماط السلوكية التي تؤدي إلى التعرّف المبكر أو النجاح الفائق
- الهدف الثالث (النماذج)**: بناء و تدريب نموذج تعلم آلة للتنبؤ بدقة بخطر تعرّف الطلاب في منتصف الفصل الدراسي
- الهدف الرابع (التوصية)**: تطوير خوارزمية لتوصية المعلمين بالإجراءات التدخلية المناسبة للطلاب المعرضين للخطر
- نطاق المشروع**: يركز على التنبؤ بسلوك الطالب ضمن مساق تعليمي واحد، باستخدام بيانات تفاعلية وحسب، ولا يشمل التقييمات اللغوية المفتوحة

---

# رحلة البيانات

من سجلات المتعلمین إلى المیزات

# البيانات: المصادر والمعالجة

## تنظيف ومعالجة البيانات

تم تنفيذ الخطوات التالية لضمان جودة البيانات:

- **معالجة القيم المفقودة:** تعبيء القيم المفقودة الخاصة بمتغيرات التفاعل على (Standard Scaling) باستخدام الصفر. - **توحيد المقاييس:** تطبيق المتغيرات الرقمية مثل الوقت المنقضي. - **هنسنة الخصائص:** إنشاء خاصية جديدة تمثل "معدل النشاط الأسبوعي" لتحسين فورة التنبؤ. - **ترقيم المتغيرات:** تحويل المتغيرات الفئوية (مثل الفرع الدراسي) إلى أرقام باستخدام One-Hot Encoding).

## مصدر البيانات

الخاصة بـ [اسم LMS] تم الحصول على البيانات من سجلات نظام إدارة التعلم المساق/الجامعة.

- **حجم البيانات:** (مثال: 5000 سجل، 25 خاصية).
- **أهم الخصائص:** وقت قضاء الطالب في المنصة، عدد مرات تسجيل الدخول، درجات الواجبات المبكرة، التفاعل مع المنتديات.

# التحليل الاستكشافي: مستويات مشاركة الطالب



أظهر التحليل الاستكشافي أن \*\*35%\*\* من الطلاب يندرجون ضمن فئة 'المشاركة المنخفضة' بناءً على تفاعلاتهم المبكرة، مما يؤكّد الحاجة الملحة إلى نظام تتبع وتدخل مبكر عبر "الذكاء الاصطناعي"

---

# المنهجية والنمذجة

بناء نموذج التنبؤ بالتعثر

# النماذج التجريبية

## النموذج الثالث Gradient Boosting ( النهائي )

خوارزمية قوية معروفة بكفاءتها في مهام التصنيف وتحقيق أعلى دقة ممكنة في مجموعات البيانات الواقعية.

## النموذج الثاني K-Means Clustering

استخدم لتجميع الطلاب إلى مجموعات بناءً على خصائص التفاعل (Segmentation) قبل تطبيق نماذج التنبؤ.

## النموذج الأول: الانحدار اللوجستي

لتقييم الحد (Baseline) استخدم كنموذج خط أساس الأدنى من الأداء المتوقع لبياناتنا.

## مقارنة وتقدير النماذج

النماذج	الدقة (Accuracy)	الاستدعاء (Recall)	الدقة (Precision)	F1-Score
الانحدار اللوجستي	0.75	0.72	0.76	0.74
شجرة القرار (Baseline 2)	0.81	0.79	0.82	0.80
**Gradient Boosting ( النهائي) **	**0.88**	**0.87**	**0.89**	**0.88**
[نموذج إضافي قمت بتجربته]	-	-	-	-

# النتائج الرئيسية

## ملخص النتائج

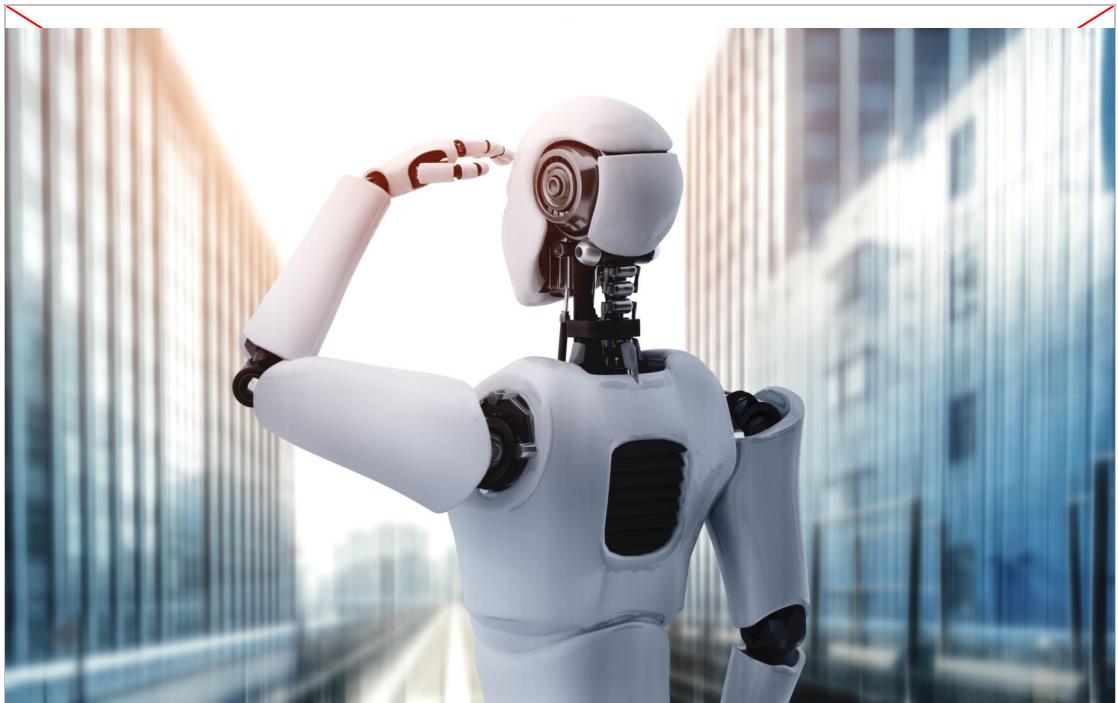
كالنموذج النهائي نظراً لأدائه المتفوق، حيث تم اختيار نموذج Gradient Boosting\*\* تم اختيار نموذج بنسبة 88%\*\*. (وهو الأهم في مهام التنبؤ بالتعثر) F1-Score حقق مقياس

هذه الدقة العالية تتيح للمؤسسات التعليمية تحديد 4 من كل 5 طلاب\*\* معرضين لخطر الرسوب بدقة، مما يتيح التدخل في الوقت المناسب لتحسين نتائجهم.

88%

دقة التنبؤ بالتعثر

# الاستنتاج والخطوات المستقبلية



## الاستنتاج

أثبت الذكاء الاصطناعي كفاءته في دعم التعلم الشخصي عبر التنبؤ الدقيق بسلوك الطلاب، مما يحول البيانات السلوكية إلى رؤى قابلة للتنفيذ لدعم كل من المعلمين والطلاب.

## الوصيات

نوصي بدمج هذا النموذج في نظام إنذار مبكر داخل منصات التعلم لاستخدامه من قبل المعلمين والإدارة.

## الخطوات المستقبلية

- دمج تحليل النصوص لتقييم جودة إجابات الطالب \*\*(NLP) معالجة اللغة الطبيعية\*\* . المفتوحة ومشاركاتهم في المنتديات.
- التخصيص التكيفي: \*\* تطوير نظام توصية متقدم يقترح مسارات تعليمية وموارد مختلفة\*\* . بناءً على تنبؤات النموذج
- لتمكين المعلمين من استخدامه (Deployment) التنفيذ: \*\* نشر النموذج كتطبيق ويب\*\* . بشكل مباشر

شكراً لكم

